

结论：还没有赢过一局（已结束 8 局，0 胜）。从「只能打到第 7 层」进步到「稳定过第一幕 boss，首次打到第二幕 boss」，第 9 局刚刚首次打过第二幕 boss，进入第三幕（第 34 层）。Jev 置信度普遍很低，最大的提升来自代码的整回合计算和 Claude 对高风险题的判断。

一、战绩

局	最高层数	结果	当时的主要变化
1	7	负	原版：纯 Jev 逐张出牌
2	17	负（第一幕 boss 墨影幻灵）	原版，作为对照组
3	22	负	上线整回合求解器、选牌评分；首次过第一幕 boss
4	22	负	改为 Claude 兜底；过第一幕 boss
5	33	负（第二幕 boss 前一层）	过第一幕 boss
6	17	负（墨影幻灵）	—
7	13	负	某些参数改动起了副作用
8	33	负（第二幕 boss 知识恶魔，打到它只剩 35 血）	上线出招预测
9	34+	进行中：首次打过第二幕 boss，进入第三幕	过瀑布巨兽；第二幕 boss 用「遭到包围」转身打法

☐胜率：0 / 8。

☐过第一幕 boss：5 次（第 3、4、5、8、9 局）。

☐到达第二幕 boss：3 次（第 5、8、9 局）；打过第二幕 boss：1 次（第 9 局）。

二、接口请求

模型	请求次数	用量	花费	延迟
Jev（经 OpenRouter）	667	103 万输入 / 4.9 万输出 token	约 \$0.045	中位 575 ms，p95 960 ms
Claude（本 session）	156	本 session 对话额度	—	作答中位 13 秒
DeepSeek	16	1.6 万 token	约 \$0.01	约 1 秒

DeepSeek 前 10 次是切换到「Claude 优先」之前的兜底，后 6 次是 Claude 90 秒内未答或答了无效选项时接手。

三、决策者分布（全部 3,764 个决策）

决策者	次数	占比	负责什么
代码	2,876	76%	整回合求解、斩杀、明显最优方案、领奖励、路线、商店、删牌等
Jev	480（另执行 156 步其方案）	13% + 4%	在接近的方案之间拍板，74% 是战斗题
Claude	156（另执行 66 步其方案）	4% + 2%	高风险题：精英、boss、事件、选牌、商店
DeepSeek	16	<1%	超时时的最后兜底
代码兜底	15	<1%	普通战斗中 Jev 太没把握时

四、Jev 的判断

置信度	次数	占比
< 0.2	106	16%

0.2 ~ 0.35	159	24%
0.35 ~ 0.5	159	24%
0.5 ~ 0.75	161	25%
≥ 0.75	67	10%

约三分之二的回答置信度不到 0.5，Jev 大多数时候没有把握。

Jev 所选方案在代码评分中的排名（战斗方案题）	次数	占比
第 1	93	69%
第 2	29	22%
第 3	7	5%
第 4	5	4%

Jev 多数时候在附和代码的最优解；它最有价值的地方，是给出「没把握」的信号，把难题交出去。

五、兜底模型的纠正

	复核次数	同意 Jev	纠正 Jev	纠正率
Claude	156	63	93	60%
DeepSeek	16	7	9	56%

题型（Claude）	复核	纠正	纠正率
选牌界面（删牌、升级、消耗、加入牌组）	21	17	81%
选牌奖励	31	21	68%
商店	16	10	63%
事件	19	11	58%
战斗方案	65	32	49%
路线	4	2	50%

Jev 在构筑类决策（选牌、升级、删牌、商店）上最弱，战斗方案相对好一些。

影响较大的几次纠正：

□构筑：第 4 局选恶魔形态而非预备打击；第 5 局阻止 Jev 用「瓶中精灵」（死亡时救命）换牌；第 8 局发现「烘焙手套 + 彼岸咆哮」「烘焙手套 + 邪眼」两个配合，后写成代码规则。

□药水时机：凌虐留到敌人出重击的回合；第 8 局对墨影幻灵把固化药水留到肢解那回合；第 9 局判断「复制药水 + 预备打击」能斩杀精英并成功。

□boss 战：第 8 局在知识恶魔身上用撕裂，把它施加的持续扣血变成每回合 +1 力量；二选一负面效果时，血量低就选「懒惰」而不叠第二层「瓦解」；第 9 局发现「遭到包围」机制，用攻击药水转身面对火箭，少挨约 13 点。

□识别坏题：多次发现候选项本身有问题（「加入牌组」被当成删牌、手牌没抽完就出题等），顺手修了代码。

六、代码迭代

□phase2 本地分支：55 次提交，167 个测试全部通过，未推送任何远端。

□求解器：从「逐张问 Jev」改为「代码搜索整回合所有出牌顺序」，建模约 40 种敌我能力、15 种药水、状态牌的回合末伤害，以及从日志学到的出招预测。

□最致命的几个 bug（均已修复）：回合开始手牌没抽完、能量没回满就开始规划甚至直接结束回合（第 4、5 局死因）；比较方案时没把用掉药水算作代价；「加入牌组」「放回抽牌堆顶」被误判成删牌；「懒惰」「瓦解」未建模（第 8 局在 boss 剩 35 血时阵亡）。

七、判断和下一步

□瓶颈正在后移：第二幕 boss 前两次都只差一口气，补上缺失的机制后，第 9 局首次打过，进入第三幕。

□离进阶 10 还很远：还没通关进阶 0，而进阶要逐级解锁。下一个里程碑是拿到第一胜。

□分工结论：Jev 不适合单独做构筑决策，但很适合当「没把握」的探测器；真正拉开差距的是代码计算和 Claude 的兜底判断。

数据来源：jev-sts2/logs/decisions.jsonl、states.jsonl、escalation/；统计脚本 ops/stats.py。